МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ
РОССИЙСКОЙ ФЕДЕРАЦИИ

Федеральное государственное автономное образовательное учреждение
высшего образования «Самарский национальный исследовательский
университет
имени академика С.П. Королева»
(Самарский университет)

Институт информатики и кибернетики
Кафедра технической кибернетики

Отчет по лабораторной работе №1

Дисциплина: «Проектирование программных комплексов»

Дисциплина: «Инженерия данных»

Выполнил: Седых М.Ю.
Группа: 6232-010402D

Самара 2025

Архитектура пайплайна

Система реализует ETL-пайплайн для обработки данных о погоде с использованием оркестрации, объектного хранилища и колоночной СУБД.

Основные компоненты

Prefect 2.x – оркестрация и планирование

Используется для декларативного описания задач, их переиспользования, логирования, планирования запусков и управления зависимостями.

Работа осуществляется через Prefect Server (REST API), который хранит метаданные выполнения в PostgreSQL.

MinIO – объектное хранилище

Применяется для хранения сырых JSON-ответов, полученных от внешнего API. Совместим с S3 и удобен для версионирования, повторной обработки и аудита данных.

Формат хранения файлов: raw/{город}/{timestamp}.json.

ClickHouse – колоночная СУБД

Используется для аналитических запросов и хранения временных рядов. Оптимизирован для высокопроизводительного чтения и агрегаций.

В системе используются таблицы weather_hourly для почасовых данных и weather_daily для дневных агрегатов.

Обе таблицы построены на движке MergeTree и упорядочены по ключам (city, timestamp) или (city, date).

Схема потока данных

Данные проходят последовательность этапов: Open-Meteo API → Extract → MinIO (raw) → Transform → Load (ClickHouse) → Telegram-уведомления.

Источник данных

В качестве источника используется Open-Meteo Forecast API/

Запросы формируются с указанием координат города (latitude, longitude), параметров почасового и дневного прогноза, временной зоны Europe/Moscow и горизонта прогноза в 2 дня.

Extract → Transform → Load

Extract

Получение прогноза выполняется через HTTP GET-запросы с таймаутом 10 секунд. Для каждого города, включая Москву и Самару, формируется отдельный запрос.

В процессе извлечения выполняется проверка статуса ответа через response.raise_for_status(), в результат добавляется поле city, после чего сырой JSON сохраняется в MinIO с временной меткой в имени файла для обеспечения версионирования.

Transform

Для почасовых данных выполняется фильтрация значений на завтрашний день, извлекаются необходимые поля из массива hourly и формируется DataFrame со столбцами timestamp, city, temperature_celsius, precipitation_mm, weather_code, wind_speed_kmh и wind_direction_degrees. Дополнительно добавляется техническое поле inserted_at.

Для дневных данных извлекаются агрегированные показатели из массива daily. Средняя температура за завтрашний день вычисляется на основе почасовых значений. Формируется запись с полями temp_min_celsius, temp_max_celsius, temp_avg_celsius, precipitation_mm, weather_code и wind_speed_max_kmh.

Данные по всем городам объединяются перед загрузкой с помощью pd.concat().

Load

Перед началом загрузки выполняется создание таблиц weather_hourly и weather_daily при их отсутствии с использованием CREATE TABLE IF NOT EXISTS. DataFrame преобразуется в список кортежей, после чего данные вставляются в ClickHouse через client.execute с оператором INSERT INTO.

Если DataFrame пустой, загрузка пропускается. Количество загруженных записей подсчитывается и возвращается для логирования в Prefect.

Качество данных

В пайплайне реализован ряд проверок качества данных.

На этапе извлечения используется HTTP-валидация через response.raise_for_status() для обработки ошибок 4xx и 5xx.

Перед загрузкой выполняется проверка пустоты данных с помощью df.empty.

При извлечении дневных данных контролируются границы массивов для предотвращения выхода за пределы индексов.

Перед отправкой уведомлений выполняется проверка наличия переменных окружения токена и id чата, необходимых для корректной работы Telegram-уведомлений.

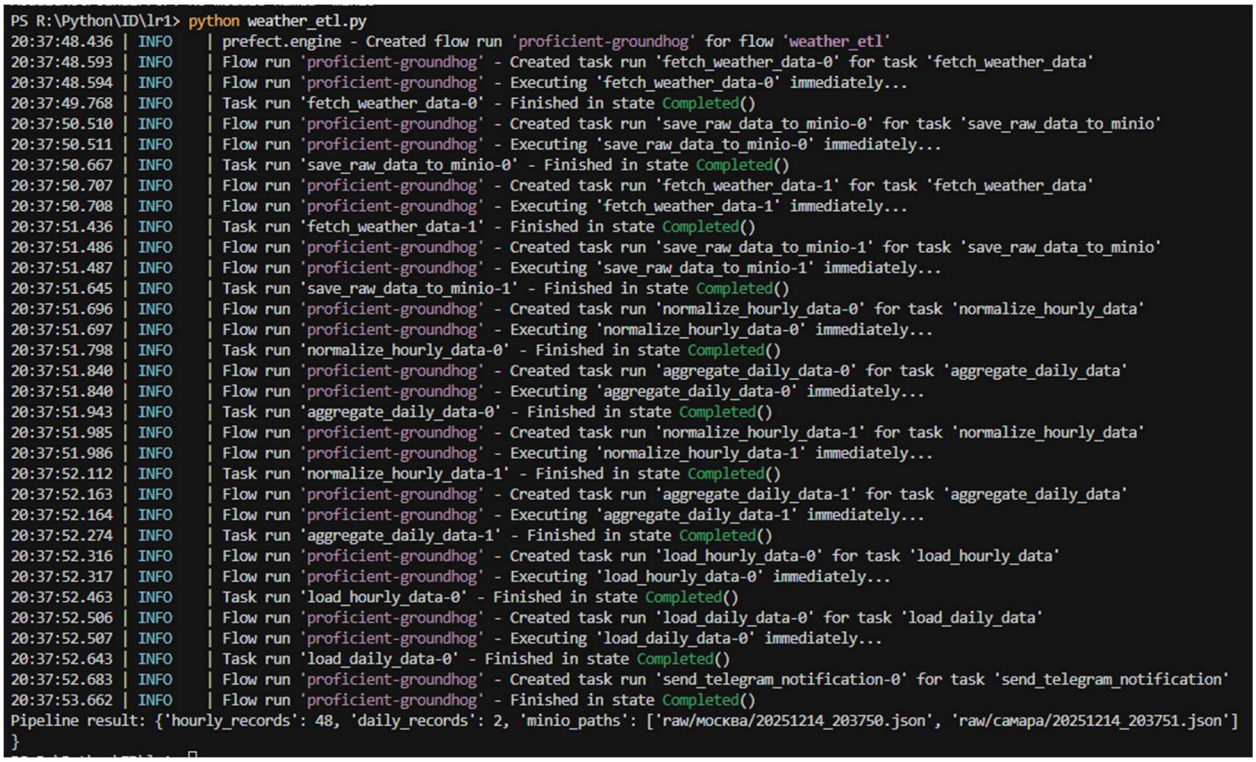

Рисунок 1 — Интерфейс Prefect с результатами выполнения flow

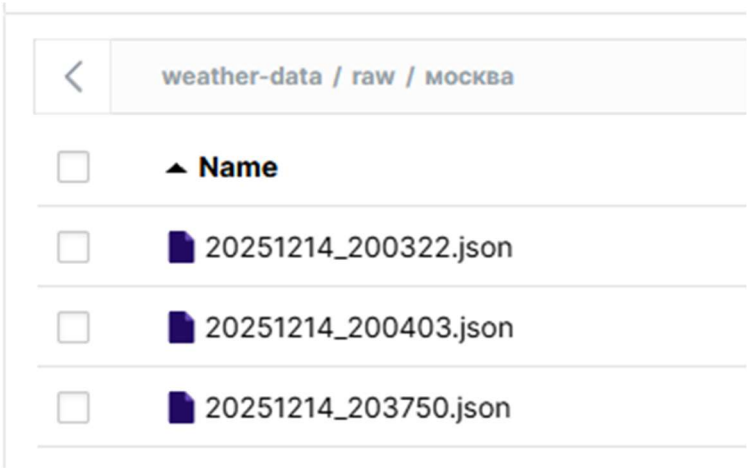

Рисунок 2 — Содержимое бакета weather-data в MinIO

На рисунке 3 показаны почасовые данные о температуре, осадках, скорости ветра и кодах погоды для города Москва на завтрашний день.

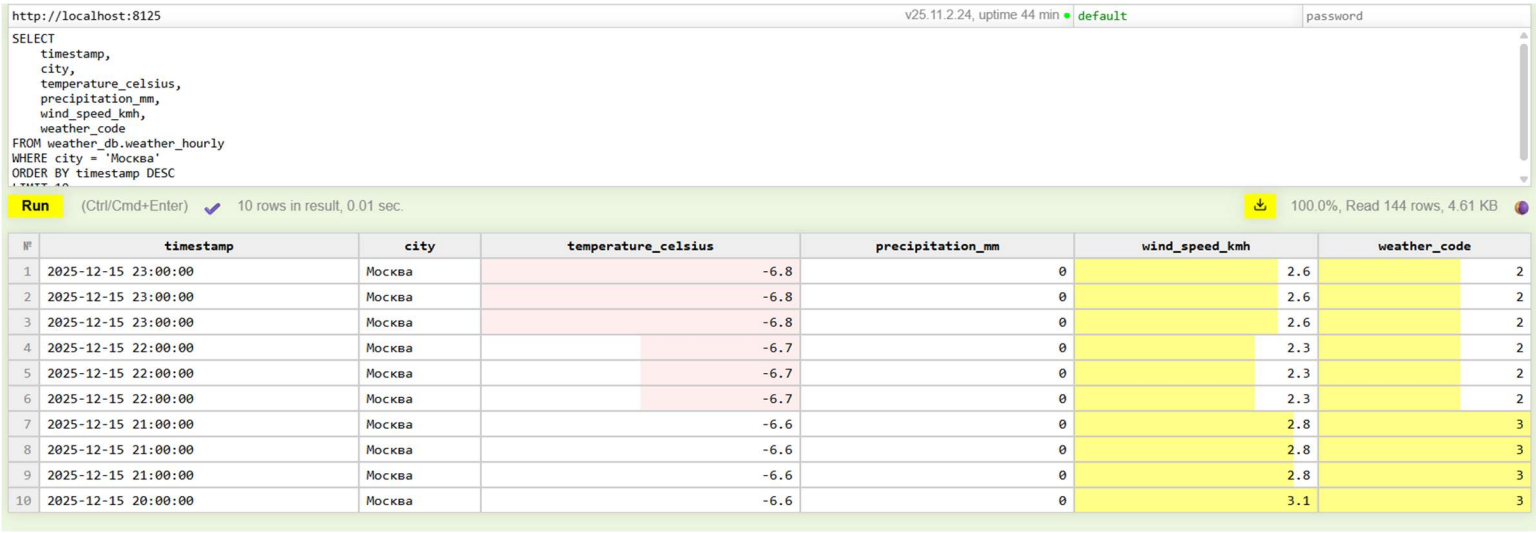

```
SELECT
    timestamp,
    city,
    temperature_celsius,
    precipitation_mm,
    wind_speed_kmh,
    weather_code
FROM weather_db.weather_hourly
WHERE city = 'Москва'
ORDER BY timestamp DESC
```

Run (Ctrl/Cmd+Enter) 10 rows in result, 0.01 sec. 100.0%, Read 144 rows, 4.61 KB

№	timestamp	city	temperature_celsius	precipitation_mm	wind_speed_kmh	weather_code
1	2025-12-15 23:00:00	Москва	-6.8	0	2.6	2
2	2025-12-15 23:00:00	Москва	-6.8	0	2.6	2
3	2025-12-15 23:00:00	Москва	-6.8	0	2.6	2
4	2025-12-15 22:00:00	Москва	-6.7	0	2.3	2
5	2025-12-15 22:00:00	Москва	-6.7	0	2.3	2
6	2025-12-15 22:00:00	Москва	-6.7	0	2.3	2
7	2025-12-15 21:00:00	Москва	-6.6	0	2.8	3
8	2025-12-15 21:00:00	Москва	-6.6	0	2.8	3
9	2025-12-15 21:00:00	Москва	-6.6	0	2.8	3
10	2025-12-15 20:00:00	Москва	-6.6	0	3.1	3

Рисунок 3 — Результаты запроса к таблице weather_hourly в ClickHouse.

На рисунке 4 показаны агрегированные дневные данные с минимальной, максимальной и средней температурой, общим количеством осадков и максимальной скоростью ветра для городов Москва и Самара.

№	date	city	temp_min_celsius	temp_max_celsius	temp_avg_celsius	precipitation_mm	wind_speed_max_kmh
1	2025-12-15	Москва	-8.9	-6.3	-7.5583334	0	8.2
2	2025-12-15	Москва	-8.9	-6.3	-7.5583334	0	8.2
3	2025-12-15	Москва	-8.9	-6.3	-7.5583334	0	8.2
4	2025-12-15	Самара	-10.1	-8.7	-9.470834	0.5	21
5	2025-12-15	Самара	-10.1	-8.7	-9.470834	0.5	21
6	2025-12-15	Самара	-10.1	-8.7	-9.470834	0.5	21

Рисунок 4 — Результаты запроса к таблице weather_daily в ClickHouse.

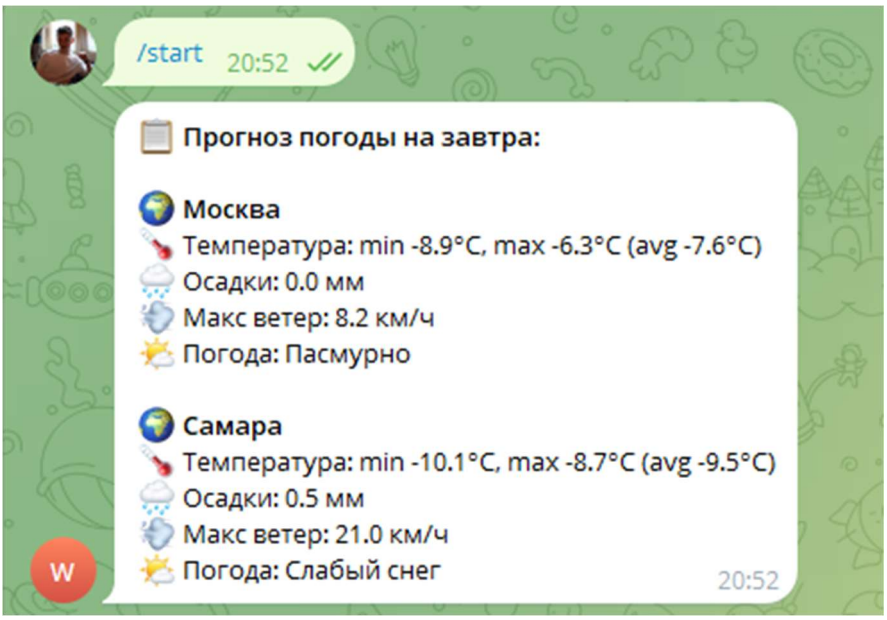

Рисунок 5 — Пример уведомления в Telegram с прогнозом погоды на завтра.

Выводы

Основной проблемой стала несовместимость Perfect с Pythom 3.14, пришлось переустанавливать. В будущем стоит добавить retry для запросов к API.